

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное

учреждение высшего образования

**«Южно-Уральский государственный университет (национальный
исследовательский университет)»**

Центр «ВиртУм»

УТВЕРЖДАЮ:

Директор ИЕТН

_____ А.А. Замышляева
_____ 2026

КУРСОВОЙ ПРОЕКТ

по дисциплине «Введение в проектную деятельность»

ЮУрГУ – 09.03.04.2026.306-220.КП

Научный руководитель:

профессор центра ОП топ-уровня в
сфере ИИ «ВиртУм»,
доктор физ.-мат. наук М.Л. Цымблер

Автор работы:

Студент группы ЕТ-142
А.В. Галкин

Работа защищена

с оценкой: _____
“ ” _____ 2026 г.

Челябинск-2026

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное

Учреждение высшего образования

«Южно-Уральский государственный университет

(национальный исследовательский университет)»

Центр «ВиртУм»

УТВЕРЖДАЮ:

Директор ИЕТН

_____ А.А. Замышляева
_____ 2026

ЗАДАНИЕ

на выполнение курсового проекта

по дисциплине «Введение в проектную деятельность»

студенту группы ЕТ-142

(Фамилия Имя Отчество студента)

Обучающемуся по направлению

09.03.04 «Программная инженерия»

1. Тема проекта

Поиск и первичный анализ датасетов по различным областям применения

2. Срок сдачи студентом законченной работы: 31.05.2026 г.

3. Исходные данные к работе

- 3.1. [Источник набора табличных данных](#)
- 3.2. [Источник набора данных с временными рядами](#)
- 3.3. [Источник набора данных с изображениями](#)
- 3.4. [Источник набора текстовых данных](#)

4. Перечень подлежащих разработке вопросов

4.1. Выбор и описание предметной области, формулировка потенциальных проблем, обзор часто используемых табличных датасетов для

сформулированных задач, обоснование, описание и первичный анализ выбранного табличного датасета.

4.2. Выбор и описание предметной области, формулировка потенциальных проблем, обзор часто используемых датасетов с временными рядами для сформулированных задач, обоснование, описание и первичный анализ выбранного датасета временного ряда.

4.3. Выбор и описание предметной области, формулировка потенциальных проблем, обзор часто используемых текстовых датасетов для сформулированных задач, обоснование, описание и первичный анализ выбранного датасета с текстами.

4.4. Выбор и описание предметной области, формулировка потенциальных проблем, обзор часто используемых датасетов с изображениями для сформулированных задач, обоснование, описание и первичный анализ выбранного датасета с изображениями.

4.5. Выбор и описание предметной области, формулировка потенциальных проблем, обзор часто используемых датасетов аудиозаписей для сформулированных задач, обоснование, описание и первичный анализ выбранного датасета аудиозаписей.

5. Дата выдачи задания: «___»_____2026 г.

Научный руководитель

М.Л. Цымблер

Задание принял к исполнению

А.В. Галкин

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	5
1. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТАБЛИЧНЫХ ДАННЫХ	7
1.1. Постановка задачи.....	7
1.2. Описание выбранного набора данных	7
1.3. Описание результатов первичного анализа	10
2. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ВРЕМЕННЫМИ РЯДАМИ	18
2.1. Постановка задачи.....	18
2.2. Описание выбранного набора данных	18
2.3. Описание результатов первичного анализа	19
3. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ИЗОБРАЖЕНИЯМИ.....	33
3.1. Постановка задачи.....	33
3.2. Описание выбранного набора данных	33
3.3. Описание результатов первичного анализа	35
4. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТЕКСТОВЫХ ДАННЫХ	41
4.1. Постановка задачи.....	41
4.2. Описание выбранного набора данных	41
4.3. Описание результатов первичного анализа	42
ЗАКЛЮЧЕНИЕ	50
ЛИТЕРАТУРА	51

ВВЕДЕНИЕ

Актуальность

Первичный анализ наборов данных необходим для задач, решаемых с помощью технологий искусственного интеллекта. Ему необходимы чистые и структурированные данные, которые можно легко проанализировать. Например, найти закономерности для обнаружения определенных объектов или свойств. Также, исходные данные должны быть качественными, чтобы обучить ИИ. Использование дубликатов, наборов с пропущенными значениями, некорректных форматов и типов данных или сильно выделяющихся данных – аномалий может привести к тому, что искусственный интеллект не сможет выполнять поставленные задачи. Аномалии могут сформировать ложные закономерности, пропущенные данные способствуют образованию ложных обобщений. В исследовании [1] на примере задачи анализа успеваемости студентов было экспериментально показано, что применение предварительной обработки таблиц приводит к повышению точности моделей машинного обучения в среднем на 5.5%

Наборы данных могут хранить в себе различную информацию. Существуют датасеты изображений, аудио, табличных данных, текста, временных рядов. Владение навыками первичного анализа данных разных типов является необходимым для специалиста в области искусственного интеллекта, чтобы обучать качественные ML-модели для успешного выполнения ими поставленных задач.

Постановка задачи

Целью курсового проекта является получение практических навыков по поиску и первичному анализу наборов данных разных типов по различным областям применения. Для достижения поставленной цели необходимо решить следующие задачи:

1) подготовить для каждого типа данных (табличные данные, временные ряды, изображения, тексты, аудио) краткое описание выбранной задачи, решение которой связано с применением технологий искусственного интеллекта;

2) подобрать для каждого типа данных набор данных из авторитетных открытых источников, необходимый для обучения ИИ-модели, решающей соответствующую выбранную задачу;

3) разработать и реализовать комплекс программ на языке Python, каждая из которых для заданного типа данных должна выполнять следующие основные функции первичного анализа: загрузка и визуализация данных, статистический анализ, выявление специфических особенностей для определенного типа данных;

4) сформулировать выводы по каждому этапу анализа, а также итоговое заключение о качестве данных и их пригодности для решения поставленной задачи;

5) разместить исходный код в репозитории системы контроля версий Git.

1. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТАБЛИЧНЫХ ДАННЫХ

1.1. Постановка задачи

Предметная область датасета: финансы. В современном мире существует серьезная проблема: мошенничество. Множество людей подвергаются давлению со стороны аферистов, взломам аккаунтов, из-за чего теряют свои сбережения и имущество. Данный набор данных позволит анализировать транзакции клиентов банков и классифицировать операции на две категории: мошеннические или обычные. Самые яркие признаки, по которым искусственный интеллект может определить класс транзакции: аномальная сумма, смена геопозиции и устройства и время перевода, которое несвойственно клиенту банка. На выходе получается класс операции.

1.2. Описание выбранного набора данных

Набор данных «`Fraud_detection_dataset`» [2] является сгенерированным и включает в себя 10.000 записей различных транзакций без пропусков. Синтетические датасеты не подходят для решения реальных задач. Не смотря на это, их можно использовать для обучающих мини-проектов, начального обучения (когда реальных данных еще нет) или тестирования системы в нестандартных условиях.

Признаки набора:

1. **transaction_id**: Уникальный идентификатор для каждой транзакции. Тип данных: строка;
2. **user_id**: Идентификатор пользователя. Тип данных: строка;
3. **amount**: Сумма транзакции. Тип данных: вещественное число;
4. **merchant_category**: Категория операции (например: АЗС, аптека, онлайн покупка). Тип данных: строка;
5. **location**: Страна, где была произведена транзакция (например: UK, AU, US). Тип данных: строка;

6. **timestamp**: Время произведения транзакции формата «ГГГГ-ММ-ДД ЧЧ:ММ:СС.МС». Тип данных: дата и время;
7. **device_type**: Устройство, на котором была произведена транзакция (например: ATM, Desktop, Mobile). Тип данных: строка;
8. **user_age**: Возраст пользователя. Тип данных: целое число;
9. **account_age_days**: Возраст аккаунта в днях. Тип данных: целое число;
10. **transaction_count_24h**: Количество транзакций за последние 24 часа. Тип данных: вещественное число;
11. **avg_transaction_amount**: Средняя сумма транзакции. Тип данных: вещественное число;
12. **is_foreign_transaction**: Осуществляется ли транзакция из-за рубежа. Тип данных: вещественное число;
13. **is_weekend**: Была ли транзакция осуществлена на выходных. Тип данных: вещественное число;
14. **hour_of_day**: Время суток. Тип данных: вещественное число;
15. **is_fraud**: Является ли транзакция мошеннической. Тип данных: логический тип (0 – нет, 1 – да);
16. **day_of_week**: День недели проведения операции (например, 0 - понедельник). Тип данных: целое число;
17. **month**: Месяц, в котором проведена транзакция. Тип данных: целое число;
18. **is_month_end**: Последние дни месяца. Тип данных: логический тип;
19. **is_month_start**: Первые дни месяца. Тип данных: логический тип;

20. **time_since_last_transaction**: Время, прошедшее с момента последней транзакции пользователя. Тип данных: целое число
21. **transaction_count_7d**: Количество транзакций пользователя за последние 7 дней. Тип данных: вещественное число;
22. **transaction_count_30d**: Количество транзакций пользователя за последние 30 дней. Тип данных: вещественное число;
23. **amount_zscore**: Z-оценка суммы текущей транзакции от среднего значения суммы транзакций пользователя. Тип данных: вещественное число;
24. **amount_percentile**: Перцентиль суммы текущей транзакции в распределении всех транзакций пользователя. Тип данных: вещественное число;
25. **amount_rolling_mean_7d**: Средняя сумма транзакций за последние 7 дней. Тип данных: вещественное число;
26. **amount_rolling_std_7d**: Стандартное отклонение суммы транзакций за последние 7 дней. Тип данных: вещественное число;
27. **location_changed**: Изменилась ли страна совершения транзакции по сравнению с предыдущей. Тип данных: логический тип;
28. **device_changed**: Изменился ли тип устройства по сравнению с предыдущей транзакцией. Тип данных: логический тип;
29. **merchant_category_changed**: Изменилась ли категория магазина. Тип данных: логический тип;
30. **risk_score**: Вероятность риска транзакции. Тип данных: вещественное число от 0 до 1;
31. **amount_x_transaction_count**: Произведение суммы на количество транзакций. Тип данных: вещественное число;

- 32. **amount_x_is_foreign**: Произведение суммы на флаг иностранной транзакции. Тип данных: вещественное число;
- 33. **transaction_count_x_is_foreign**: Произведение количества транзакций на флаг иностранной транзакции. Тип данных: целое число;
- 34. **is_rush_hour**: Час-пик. Тип данных: логический тип;
- 35. **is_off_hours**: Нерабочее время. Тип данных: логический тип;
- 36. **avg_amount_ratio**: Отношение суммы транзакции к среднему значению. Тип данных: вещественное число;
- 37. **transaction_velocity**: Количество транзакций за единицу времени. Тип данных: вещественное число.

Исходя из списка всех признаков можно сказать, что все данные, кроме возраста, были анонимизированы. Например, вместо потенциальных имени и фамилии представлен некий идентификатор пользователя. Локации, где были проведены транзакции сведены к двухбуквенным кодам стран.

1.3. Описание результатов первичного анализа

1.3.1 Визуализация распределения категориальных признаков

На рис. 1.0 представлено распределение классов обычных и мошеннических транзакций.




Рисунок 1.0. Распределение классов транзакций

Исходя из информации на графике можно сказать, что мошеннических транзакций очень мало, что может привести к недообучению модели. Требуется дополнить датасет.

На рис. 1.1 отображено распределение остальных категориальных признаков.




Рисунок 1.1. Распределение merchant_category, device_type, location

На графиках видно равномерное распределение данных признаков.

На рис. 1.2 представлены графики распределения некоторых значений для числовых признаков табличного набора данных.




Рисунок 1.2. Графики распределения числовых признаков (Левый график – распределение возраста, правый график – распределение транзакций по часам дня)

На основе рис. 1.2 можно сделать следующие выводы. Анализ распределения признака **user_age** показывает равномерное распределение возраста от 18 до 79 лет, но людей младше от 18 до 20 лет и от ~75 до 79 лет больше по сравнению с другими возрастами. Это не критично, но искусственный интеллект может найти в этом ошибочную закономерность. К примеру, если в этой возрастной группе много мошеннических операций, то ИИ, исходя из возраста пользователя, может предположить, что транзакция была преступной. На втором графике распределения (**hour_of_day**) транзакций по часам дня видно равномерное распределение.

1.3.2. Анализ на наличие пропусков в данных

В табл. 1.1 приведена информация по количеству пропущенных значений в основных признаках набора данных.

Таблица 1.1. Количество и доля пропущенных значений по основным признакам

Признак	Количество пропусков	Доля пропусков, %
transaction_id	0	0
user_id	0	0
amount	0	0
merchant_category	0	0
location	0	0
timestamp	0	0
device_type	0	0
user_age	0	0
account_age_days	0	0
transaction_count_24h	0	0
avg_transaction_amount	0	0
is_foreign_transaction	0	0
day_of_week	0	0
hour_of_day	0	0
is_fraud	0	0

Можно увидеть, что признаки набора не содержат пропусков. Отсутствие пропущенных значений позволяет использовать все записи для анализа и построения модели.

1.3.3. Построение тепловых карт

На рис. 1.3 представлена тепловая карта мошеннических транзакций по дням недели и времени суток.




Рисунок 1.3. Тепловая карта преступных транзакций по дням и времени

Наблюдается следующая ситуация: в большинстве случаев мошеннические транзакции проходят в нерабочие часы.

На рис. 1.4 представлена большая корреляционная карта по всем признакам из датасета.




Рисунок 1.4. Тепловая карта всех признаков набора данных

Исходя из графика можно увидеть, что признаки, которые связаны с суммой транзакции сильно коррелируют с признаком amount. Также, между признаком is_fraud и несколькими основными признаками (amount, account_age_days, avg_transaction_amount, is_foreign_transaction) имеется слабая корреляция.

1.3.4. Сравнение признака при разных значениях другого признака

На рис. 1.4 представлены свечи, по которым можно сравнить суммы транзакций мошеннических и обычных.




Рисунок 1.4. Свечи для сравнения сумм транзакций (0 – обычная транзакция, 1 – мошенническая)

По данному графику можно предположить, что мошеннические транзакции производятся на большие суммы денег, нежели обычные, хотя выбросы у обычных транзакций в виде больших сумм так же имеются.

В табл. 1.2. представлены выбросы у обычных и мошеннических транзакций.

Таблица 1.2. Количество выбросов у транзакций разных классов и их доля в своем классе

Обычные транзакции	Мошеннические транзакции
847 (8.9% из 9500)	53 (10.6% из 500)

1.3.5. Гипотезы для неэтичного использования датасета

1. Гипотеза о дискриминации по географическому признаку

Если в определенном регионе больше всего происходит мошеннических операций, то ИИ может начать предполагать, что все транзакции из этого региона преступные.

2. Гипотеза о дискриминации по возрасту

Если в какой-либо группе возрастов произошло больше всего мошеннических операций, то ИИ может начать основываться на возрасте пользователя, что не корректно в данной сфере.

Потенциальные возможности расширения датасета: добавить больше мошеннических транзакций.

Вывод по первому разделу

Набор данных «**Fraud_detection_dataset**» – **синтетический** датасет для обучения искусственного интеллекта классифицировать мошеннические и обычные транзакции. В нем большое количество данных, но мало преступных операций в соотношении с обычными. Ключевыми особенностями набора являются: отсутствие пропусков, большого дисбаланса в распределениях признаков, шума. Также, датасет анонимизирован, чтобы не распространять чувствительные данные пользователей. Требуется дополнить набор данных мошенническими транзакциями.

2. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ВРЕМЕННЫМИ РЯДАМИ

2.1. Постановка задачи

Предметная область датасета: промышленность. Набор данных относится к прогнозированию. Искусственный интеллект должен научиться определять, когда подшипник может выйти из строя, исходя из его вибраций и температуры. Решение данной задачи может быть интересно заводам с промышленным оборудованием. Если не уследить за деталями, которые быстро изнашиваются, то производство замедлится или остановится на неопределенное количество времени, что повлечет убытки.

2.2. Описание выбранного набора данных

Набор данных «Ball Bearing Vibration, and Temperature Run-to-Failure Dataset» [3] представляет собой 129 файлов формата .csv, каждый из которых показывает работу подшипника за один час (период эксплуатации подшипника – 128 часов). Файлы состоят из 4 столбцов:

1. **Вибрация по оси ОХ.** Тип данных: вещественное число;
2. **Вибрация по оси ОУ.** Тип данных: вещественное число;
3. **Температура подшипника в градусах Цельсия.** Тип данных: вещественное число;
4. **Температура атмосферы в градусах Цельсия.** Тип данных: вещественное число.

Данные о вибрации и температуре собираются с частотой дискретизации 25,6 кГц. Длительность данных составляет 78.125 секунд. Модель датчика вибрации: РСВ 352С34. Модель датчика температуры: термопара типа К.

Характеристики подшипника:

- Модель: NSK 6205 со стальным уплотнением
- Вес подшипника: 0.13 кг

- Внутренний диаметр: 25 мм
- Наружный диаметр: 52 мм
- Ширина: 15 мм
- Максимальная частота вращения: 13000 об/мин
- Номинальная динамическая нагрузка: 14.8 кН
- Номинальная статическая нагрузка: 7.8 кН

На рис. 2.0 представлено изображение подшипника.



Рисунок 2.0. Подшипник NSK 6205

2.3. Описание результатов первичного анализа

2.3.1. Загрузка и первичное знакомство

Фактическая структура данных совпадает с описанием из источника. Длина ряда составляет 129 часов. Временной ряд является многомерным, так как можно составить несколько временных рядов с разными признаками (например, температура подшипника и время, температура в атмосфере и время). В наборе данных отсутствуют временные метки, кроме названий файлов в формате год-месяц-день-часы-минуты. Преобразований не требуется, так как эти данные не влияют на обучение модели.

2.3.2. Визуализация исходных данных

На рис. 2.1 представлены два графика изменения температуры подшипника и атмосферы во времени.




Рисунок 2.1. Изменение температуры подшипника (е) и атмосферы (f) во времени (взято из официального исследования)[\[4\]](#).

На основе рис. 2.1 можно сказать, что у температуры атмосферы (f) нет серьезных колебаний, что благоприятно для обучения модели: эта температура несильно скажется на подшипнике. Также, можно заметить, что со временем работы подшипника, его температура постепенно изменяется и приобретает аномальные значения (е), по которым можно спрогнозировать скорую поломку детали, начиная от +- 90 часов работы. Из аномалий можно выделить два типа: точечные (на +- 105–108 часов работы) и коллективные (примерно на 117 и далее часов работы). Со временем в целом просматривается рост температуры. Разрывов не наблюдается.

Рис. 2.2 отображает несколько данных, которые показывают, как энергия вибрации увеличивается и уменьшается. Через некоторое время эксплуатации подшипника, на нем образовался скол, который увеличил вибрацию, а после

смещения уменьшил. После окончательного выхода из строя вибрация снова увеличилась.




Рисунок 2.2. Графики вибраций во времени: (а) – виброускорение прохождения шариков по внутреннему кольцу, (б) – виброускорение прохождения шариков по внешнему кольцу, (с) – виброускорение вращения шариков, (d) – среднеквадратичное значение вибрации
(взято из официального исследования)[\[4\]](#).

По оси ОХ отображается все время работы подшипника. Ось ОУ показывает виброускорение. Оно напрямую характеризует динамические силы, воздействующие на детали и узлы внутри работающего механизма: график отображает насколько резко и сильно детали подшипника меняют направление своего движения при тряске. Измерение именно

виброускорения позволяет эффективно фиксировать высокочастотные микро-удары от зарождающихся дефектов.

На графике (а) можно выделить точечные аномалии (например, на 48 часах работы) и коллективные (например, резкое уменьшение вибрации от 48 до +- 72 часов работы). На всех остальных графиках наблюдаются точечные аномалии резкого повышения вибрации.

На рис. 2.3. показаны среднеквадратичные значения вибрации по оси ОХ и вибрации по оси ОУ и средние значения температур подшипника и атмосферы.




Рисунок 2.3. Данные по всем измерениям датасета

Можно заметить, что после 120 часов работы, вибрация и температура резко увеличилась. После 129 часов работы исследование было закончено.

Средние значения были взяты из-за того, что данных очень много и обработать данные становится тяжелой задачей. Среднеквадратичные

значения берутся потому, что среднее значение вибрации может быть равно нулю из-за отрицательных значений.

2.3.3 Статистический анализ

Таблица 2.1. Статистические характеристики набора данных

	Vibration_X	Vibration_Y	Temp_Bearing	Temp_Atmosphere
Count	2.579937e+08	2.579937e+08	2.579896e+08	2.579896e+08
Mean	0.006587737	0.01444664	42.54523	25.49339
Std	0.4234042	0.6534180	11.43994	0.5129180
Min	-51.02237	-44.48412	30.09578	24.40789
Q1	-0.1459880	-0.2555203	36.50803	25.12951
Q2	0.04579356	0.04950974	39.69116	25.57302
Q3	1.036248	1.134837	44.87347	25.78651
Max	39.69520	10.68812	108.8404	26.77077

По таблице можно увидеть, что максимальные значения, за исключением температуры атмосферы, за допустимыми пределами, когда подшипник уже изнашивался и требует замену. Также, средние значения и медианы достаточно близки к друг-другу, что можно назвать симметричным распределением. Частота дискретизации везде равна 25.6 кГц. Разброс между значениями вибрации небольшой и составляет 0.2300138, что не требует масштабирования данных. Из неинформативных каналов можно выделить температуру атмосферы, так как она почти никак не изменяется.

2.3.3. Анализ пропусков и выбросов

Табл. 2.2 отображает пропущенные значения и выбросы по каждому каналу временного ряда.

	Пропуски (%)	Выбросы (аномалии)
Vibration_X	0.002–0.004	2352734
Vibration_Y	0.002–0.004	3698449
Temp_Bearing	0.002–0.0041	-
Temp_Atmosphere	0.002–0.0041	-

Пропуски почти нулевые. Возможно, при передаче данных был потерян маленький процент или что-то случилось с датчиком в определенные моменты. Максимальная последовательность пропущенных строчек: 41. Такой маленький процент пропусков можно либо удалить, что не повлечет за собой большие потери. Также, альтернативный вариант – восстановление с помощью линейной интерполяции, когда логически дописывается пропущенное значение.

Выбросы были вычислены по следующему правилу трех сигм: $\text{mean} \pm 3 \cdot \text{std}$. Это диапазон нормальных значений подшипника для каждого файла. На рис. 2.4 представлен график выбросов для каждого часа работы. По этому правилу невозможно посчитать выбросы температуры подшипника, так как в течение всей работы его температура постепенно повышается, а затем резко увеличивается примерно на 120 часу работы, относительно предыдущих часов.




Рисунок 2.4. Динамика количества выбросов за все время работы

2.3.4. Анализ диапазонов значений

На рис. 2.5 представлены диапазоны значений по всем файлам




Рисунок 2.5. Диапазон значений за все часы работы

На диаграмме можно увидеть, что вибрации находятся примерно на одном диапазоне, что нельзя сказать про температуры ("Vibration_X" ∈

$[-51.02; 39.695]$, "Vibration_Y" $\in [-44.484; 10.688]$, "Temp_Bearing" $\in [30.095; 108.84]$, "Temp_Atmosphere" $\in [24.407; 26.77]$). Стоит учесть, что данный график составлялся с шагом 1000, так как пройти полностью по всему набору достаточно трудоемкий процесс. Этот шаг мог пропустить некоторые выбросы, но этого вполне достаточно для построения графика. В целом диапазоны имеют разный размах, что может привести к доминированию одного измерения над другим. Например, модель будет считать температуру подшипника более важной, чем вибрацию, так как значение температуры намного выше. Для решения данной проблемы требуется стандартизация признаков. Из-за наличия выбросов, которые просматриваются на графике, рассчитывать стандартизацию через среднее значение нецелесообразно (при помощи StandardScaler из библиотеки scikit-learn), так как выбросы будут входить в стандартное отклонение, а нормальные значения будут около нулевыми. В данной ситуации лучше всего использовать метод, который работает с медианой и квантилями – RobustScaler из той же библиотеки, где значения преобразуются по формуле $z = \frac{x - \text{Медиана}}{Q3 - Q1}$, где x – исходное значение, медиана – значение, которое находится посередине отсортированного списка всех значений, $Q3$ – 75-й перцентиль, $Q1$ – 25-й перцентиль. Таким образом нормальные значения будут в стандартном отклонении, а выбросы большими, что уравнивает измерения. Выбросы в свою очередь можно учитывать, чтобы определять поломку подшипника: можно добавить новое измерение, в котором будет отображено количество выбросов за определенный промежуток времени относительно конкретной строки. Если их много, вероятнее всего, подшипник сломался.

2.3.5. Корреляционный анализ

На рис. 2.6 представлена тепловая карта корреляции столбцов в наборе данных.




Рисунок 2.6. Зависимость всех показателей между собой

Наблюдается следующее: отрицательная корреляция отсутствует. Имеется небольшая корреляция между вибрациями по оси x и y. Также, можно заметить, что температура атмосферы и температура подшипника имеют коэффициент 0.6. Чтобы ИИ не принимал повышение температуры атмосферы за поломку подшипника, нужно добавить новое измерение – разницу температур подшипника и атмосферы. Таким образом, если разница будет увеличиваться, то это будет значить, что повышается именно температура самого подшипника. На протяжении всей работы детали внешняя температура изменилась с 24.4 градусов по Цельсию до 26.7 градусов. Это не значительное изменение, поэтому нельзя сказать, что температура атмосферы сильно повлияла на подшипник. Последнее, что можно увидеть: никакой линейной корреляции нет между температурами и вибрациями подшипника. Внешняя температура относительно вибраций – уникальное значение. Также, вибрации никак не влияют на температуру подшипника и наоборот, ведь сильные вибрации вызываются дефектами в самом подшипнике.

2.3.6. Поиск и анализ шумов

На рис. 2.7 представлен анализ температуры подшипника с шумом и без шумов




Рисунок 2.7. Декомпозиция канала с температурой исправного подшипника

Первый график – исходный ряд.

Второй график – тренд. Можно увидеть, что тренд плавно поднимется вверх. Это означает, что подшипник стабильно греется из-за естественного трения.

Третий график – сезонность. Здесь отображена сезонность за час, так как был проанализирован один файл. Она очень незначительная и колеблется примерно от -0.005 до ~0.01, что характерно для стабильной работы.

Четвертый график – шумы. Видная низкая амплитуда, которая колеблется около нуля. Это могут быть случайные помехи датчика. Также, на графике видны одиночные выбросы. Значение $SNR = 19.79$ достаточно высокое, что означает чистоту данных.

Теперь рассмотрим файл, где подшипник уже перегрелся и работает неисправно. На рис. 2.8. показаны тренд и сезонность в таких условиях.




Рисунок 2.8. Декомпозиция канала с температурой неисправного подшипника

На втором графике видны колебания и увеличение температуры. Это связано с деформацией подшипника. Возможно, деформация сгладила трение, из-за чего температура на время начала падать. Такие «волны» – это прямой признак того, что подшипник сломан.

Третий график показывает следующее: у сезонности увеличился диапазон, и ее цикл увеличился и стал более рваным.

Последний график расширился в разбросе и стал волнистым. Это означает, что температура скачет из-за небольших заклиниваний и неравномерного трения. Снижение SNR так же может говорить о том, что подшипник неисправен, так как появилось много лишнего шума.

Как итог: при исправной работе была плавная динамика тренда и небольшая амплитуда сезонности. Когда подшипник перегрелся и деформировался, температура начала неестественно колебаться, а сезонность расширилась в диапазоне и периодически увеличивалась и оставалась на более высоких значениях.

Далее рассмотрим декомпозицию вибрации тех же файлов. На рис. 2.9 представлена декомпозиция вибрации по оси X: слева исправный подшипник, справа поврежденный. На рис. 2.10. отображена декомпозиция вибрации по оси Y.




Рисунок 2.9. Декомпозиция вибрации по оси X исправного подшипника (слева) и поврежденного (справа)

Можно увидеть, что главное отличие исправного подшипника от поврежденного это увеличение диапазона у всех графиков примерно в 4 раза: тренд стал размашистым (так как вал уже не вращается ровно), диапазон сезонности увеличился (оборот вала сопровождается сильным ударом), у шума так же увеличился разброс (при неисправном подшипнике лишних шумов намного больше).

SNR у вибрации считать не целесообразно, так как вибрация очень похожа на шум (у нее нет плавного тренда). В этом случае необходимо рассчитать RMS (среднеквадратичное значение), которое показывает общую энергию вибрации. Изначально RMS был равен 0.3621. Когда подшипник стал неисправен, значение поднялось в 4 раза до 1.4518. Это показывает, что деталь шумит сильнее. Схожая ситуация просматривается на рис. 2.10.




Рисунок 2.10. Декомпозиция вибрации по оси Y. исправного подшипника (слева) и поврежденного (справа)

В случае этой вибрации среднеквадратичное значение выросло почти в три раза: с 0.5714 до 1.5896.

Выводы по второму разделу

Набор данных «**Ball Bearing Vibration, and Temperature Run-to-Failure Dataset**» - большой набор для прогнозирования поломки подшипника, исходя из температуры и вибрации. В нем представлены вибрации по двум осям, температура работающего подшипника и атмосферы. В датасете почти отсутствуют пропуски. Дубликаты полностью отсутствуют. Имеются

аномалии, с помощью которых можно спрогнозировать скорую неисправность подшипника. Шумы удовлетворительные. Это означает, что модель сможет выделить из них нужные данные, но для повышения точности требуется фильтрация. Набор можно использовать для решения поставленной задачи.

3. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ИЗОБРАЖЕНИЯМИ

3.1. Постановка задачи

Предметная область набора данных: охрана порядка и культурного наследия в городе. Вандализм – распространенная проблема в любом городе. Вандалы наносят ущерб населенному пункту и культуре: разрисовывают здания и памятники краской, разрушают мемориалы и тому подобное. Цель датасета: детекция граффити на фото. На вход подается фотография, в которой искусственный интеллект находит и отмечает различные граффити на памятниках и стенах. В этом могут быть заинтересованы власти городов. Это поможет быстрее обнаружить граффити и ликвидировать его. Для обучения модели распознавать объекты, необходимы размеченные фото.

3.2. Описание выбранного набора данных

Набор данных «STORM graffiti/tagging detection dataset» [5] представляет собой 1021 изображение с граффити и их разметкой в файле формата .csv. Данные собирались университетом Западной Аттики (University of West Attica) в Греции с помощью камеры смартфона для проекта STORM (Safeguarding Cultural Heritage through Technical and Organisational Resources Management) [6]. Это проект Европейского союза по охране культурного наследия. Набор данных распространяется под лицензией CC BY 4.0, которая разрешает делиться и адаптировать датасет, но только при указании авторов и правообладателей и изменений. Датасет имеет большое количество размеченных фотографий и разнообразные места съемки: стены, тротуары, скамейки и статуи. Также, на фотографиях может быть больше одного рисунка, которые нужно распознать. Неинформативные части фотографий были обрезаны с целью анонимизации датасета, но на некоторых фотографиях все равно присутствуют номера автомобилей.

Формат аннотации собственный в .csv файлах, но похож на Pascal VOC. В табл. 3.1 представлены сравнения координат в датасете с форматом Pascal VOC.

Таблица 3.1. Сравнение представления координат с Pascal VOC

Координаты в наборе данных (.csv)	Координаты Pascal VOC (.xml)
xmin, ymin, xmax, ymax	<xmin>, <ymin>, <xmax>, <ymax>

Структура каталогов и аннотаций:

- **Разметка фото:**
imagesofgraffiti\bounding_boxes\test_labels.csv,
imagesofgraffiti\bounding_boxes\train_labels.csv
- **Фото:**
imagesofgraffiti\images\test, imagesofgraffiti\images\train

Структура файлов разметки формата .csv:

1. **Filename:** имя фотографии с форматом. Тип данных: строка;
2. **Width:** ширина фотографии в пикселях. Тип данных: целое число;
3. **Height:** высота фотографии в пикселях Тип данных: целое число;
4. **Class:** выделенный объект на фотографии (Graffiti) Тип данных: строка;
5. **Xmin:** координаты по оси ОХ левой нижней точки бокса граффити. Тип данных: целое число;
6. **Ymin:** координаты по оси ОУ левой нижней точки бокса граффити Тип данных: целое число. Тип данных: целое число;
7. **Xmax:** координаты по оси ОХ правой верхней точки бокса граффити Тип данных: целое число. Тип данных: целое число;
8. **Ymax:** координаты по оси ОУ правой верхней точки бокса граффити Тип данных: целое число. Тип данных: целое число.

Ограничения во время сбора датасета:

- Фотографии были сделаны только в муниципалитете Афин и его пригородах;
- Отсутствуют изображения в темное время суток.

3.3. Описание результатов первичного анализа

3.3.1. Анализ количества и баланса классов

На рис. 3.1 представлены все классы из набора данных.




Рисунок 3.1. Классы в датасете

Из графика видно, что существует только один класс Graffiti. Общее количество записей в .csv файлах составляет 2339. Это означает, что в большинстве случаев на фотографиях больше одного рисунка и датасет относится к задаче детекции.

3.3.2. Пропущенные данные в разметке

В табл. 3.2 представлено количество пропусков в общей разметке датасета

Таблица 3.2. Пропуски в разметке

Атрибуты разметки	Количество пропусков
Filename	0
Width	0
Height	0
Class	0
Xmin	0
ymin	0
Xmax	0
ymax	0

3.3.2. Примеры типичных изображений

Рис. 3.2, 3.3, 3.4 показывают примеры типичных изображений из набора данных.



Рисунок 3.2. Пример №1



Рисунок 3.3. Пример №2



Рисунок 3.4. Пример №3

Все фото с разрешением 720 x 960. На некоторых фотографиях запечатлены сразу несколько граффити. На рис 3.3 можно увидеть разное освещение: на одно граффити светит солнце. Рисунки имеют разные размеры и расположены на различных поверхностях: железная дверь на рис 3.4, бетонные стены на рисунках 3.2 и 3.3. На рис. 3.4 можно заметить, что фотография обрезана. Возможно, на этом месте были чувствительные данные, которые нужно скрыть.

3.3.3. Количество граффити на фотографиях

На рис. 3.5 представлено распределение количества граффити на фотографиях




Рисунок 3.5. Распределение количества фотографий на фото

Из графика видно, что на фотографиях в большинстве случаев по 1–3 граффити и изредка большее количество.

3.3.4. Процент занятой граффити площади на фотографиях

На рис. 3.6 показан процент, который занимают граффити на фото с учетом наложения боксов разных граффити друг на друга.




Рисунок 3.6. Процент занятой граффити площади фото

Изучив график, можно отметить, что в среднем граффити занимает 9.4% от площади фото. Также, есть малое количество фотографий, где процент занимаемой площади превышает 40%: на этих фото, в большинстве случаев, более 1 граффити. Максимально занятый процент площади составляет 62.78%. Максимальный процент наложения боксов друг на друга равен 57.97% (файл: IMG_20180713_110209.jpg).

Выводы по третьему разделу

Набор данных «**STORM graffiti/tagging detection dataset**» – датасет, в котором представлены граффити в разнообразных местах и поверхностях, начиная от стены здания, заканчивая памятником и скамейкой. Также, рисунки были запечатлены при разных освещениях, но отсутствуют ночные и вечерние фотографии. Большинство фото были анонимизированы путем обрезания

частей, где находятся люди или номера автомобилей, но встречаются файлы, в которых такие объекты присутствуют. Возможно добавление фотографий для дальнейшей их разметки. Данный набор подходит для поставленной задачи.

4. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТЕКСТОВЫХ ДАННЫХ

4.1. Постановка задачи

Предметная область набора данных: компьютерная и информационная безопасность. Спам сообщения нередко поступают на электронный ящик каждому пользователю. Они могут быть безобидными и не нести какой-либо полезной информации. Также, спам отправляют злоумышленники с целью заразить компьютер вирусными файлами, чтобы завладеть им в своих целях. От спама могут пострадать как обычные пользователи, так и различные компании. Цель датасета – классификация электронных писем: является ли оно спамом. Этим могут быть заинтересованы разработчики сервиса электронной почты или отдельные компании, использующие электронную почту. На вход должна подаваться информация из письма, а на выходе класс сообщения: спам это или нет.

4.2. Описание выбранного набора данных

Набор данных «**Enron Spam Dataset**» [7] представляет собой файл формата .csv с информацией о письмах и сами сообщения. Всего в датасете 33716 писем на английском языке. Он был составлен на основе статьи «Spam Filtering with Naive Bayes - Which Naive Bayes?» [8]. Авторы статьи использовали корпус сообщений «SpamAssassin» [9], в котором хранятся настоящие классифицированные электронные письма.

Структура набора данных:

1. **Message ID**: порядковый номер сообщения в датасете. Тип данных: целое число;
2. **Subject**: тема сообщения. Тип данных: строка;
3. **Message**: текст письма. Тип данных: строка;
4. **Spam/Ham**: класс сообщения: spam/ham. Тип данных: строка;
5. **Date**: дата отправки сообщения. Тип данных: дата формата ГГГГ-ММ-ДД.

Из чувствительных данных можно отметить электронные почты, которые, имена людей, номера телефонов.

4.3. Описание результатов первичного анализа

4.3.1. Анализ количества и баланса классов

На рис. 4.1 отображен баланс классов писем спам/не спам.




Рисунок 4.1. Баланс классов spam (спам письмо) и ham (не спам письмо)

Исходя из графика, можно заметить примерно одинаковое количество спам и не спам сообщений: spam = 17171 (50.93%) и ham = 16545 (49.07%), что положительно скажется при обучении модели. Дисбаланс по количеству разного вида писем составляет 626 в сторону спам сообщений.

4.3.2. Анализ на наличие пропусков

В табл. 4.1 представлены пропуски в столбцах набора данных

Таблица 4.1. Количество пропусков и их доля

Признак	Количество пропусков	Доля пропусков (%)
Message ID	0	0
Subject	289	0.86
Message	371	1.11
Spam/Ham	0	0
Date	0	0

По таблице можно увидеть, что имеются пропущенные данные в очень малом количестве. Возможно, они были потеряны при передаче данных, или сборе датасета, или некоторые письма не имеют текста / темы. Такое небольшое количество не повлияет на обучение ИИ. При необходимости датасет можно дополнить.

4.3.3. Анализ количества слов и длин сообщений и тем в письмах

На рис. 4.2 представлены два графика, которые отображают среднее количество слов и символов в сообщениях и их темах. Слева представлены средняя длина сообщения (синий цвет) и среднее количество слов в сообщении (зеленый цвет). Справа отображены средние значения количества слов в теме письма (фиолетовый цвет) и символов тем (красный цвет).




Рисунок 4.2. Усредненные значения количества слов и символов в сообщениях и их темах.

Subject_len и **Message_len** – длины темы и сообщения соответственно. **Words_in_Subject** и **Words_in_Message** – количество слов в теме и сообщении соответственно.

Из графиков можно увидеть, что спам письма отличаются меньшим количеством слов в сообщении, но при этом чуть большим числом слов в темах. Можно предположить, что спам письма пытаются сильнее выделиться среди всех писем на почте и несут меньшую информацию в самом сообщении. Главная задача спам письма заставить пользователя нажать на него и перейти по вредоносной ссылке или скачать вирусный файл. С такой тактикой спам письмо может достичь своей цели с большей вероятностью.

4.3.4. Сравнение классов писем по диапазону количества слов

На рис. 4.3 представлен график сравнение классов писем по количеству слов




Рисунок 4.3. сравнение классов писем до 160 слов и более 160 слов

По графику видно, что письма, которые превышают в себе 160 слов с большей долей вероятности являются не спамом. Вероятность встретить спам в длинных письмах (более 160 слов) составляет 0.446. Это подкрепляет предположение, которое было сделано в пункте 4.3.3.

Количество слов для разделения писем было взято не случайно: алгоритм нахождения данной границы перебирает значения (количество слов в письме) до 1000 с шагом 10, считает спам письма, длина которых не больше значения, и не спам письма, длина которых больше значения. Далее он просчитывает точность (среднее значение количества таких спам и не спам писем). После перебора всех значений получается количество слов, которое лучше всего подходит для сравнения классов писем. На рис. 4.4 представлен код вычисления.

```

best_threshold = 0
max_accuracy = 0

for t in range(10, 1000, 10):
    correct_spam = len(file[(file['Spam/Ham'] == 'spam') & (file["Words_in_Message"] <= t)])
    correct_ham = len(file[(file['Spam/Ham'] == 'ham') & (file["Words_in_Message"] > t)])

    # Считаем точность такого правила
    accuracy = (correct_spam + correct_ham) / len(file)

    # Если точность лучше предыдущей, запоминаем этот порог
    if accuracy > max_accuracy:
        max_accuracy = accuracy
        best_threshold = t

print(f"Математически оптимальный порог: {best_threshold} слов")

```

Рисунок 4.4. Реализация вычисления количества слов для сравнения классов писем

4.3.5. Исследование с использованием GPT-систем

Был проведен следующий эксперимент: 4 GPT-системам был предложен набор данных с просьбой классифицировать письма самостоятельно, после чего сравнить свою классификацию с датасетом. Также, были выбраны случайно конкретные письма для того, чтобы визуальнo оценить, что сделали GPT-системы. ID писем в наборе данных: **0, 1, 23896, 8260, 8245, 18139, 31769, 31774, 33715.**

В общем, можно сказать, что результаты совпадают с классификацией в датасете.

1. Gemini от Google (Версия: 3.1 flash-lite):

Опираясь на содержание, стиль написания, наличие характерных для спама признаков (срочность, обещания заработка, странные ссылки, нетипичные заголовки) и контекст корпоративной переписки.

Итог: классификация совпала со всеми письмами. Система отмечает, что спам и рабочая переписка – это абсолютно разные вещи. У ham писем имеется контекст: имена сотрудников, рабочие процессы. Также, переписка выглядит как диалог и содержит слэнг. Что касается

spam писем: в них используются методы для обхода фильтров: разбивка слов, неуместные символы. Также, письмо 18139 имеет очень много случайных слов, что так же является методом для запутывания спам-фильтра.

2. Grok (Версия: Fast):

Анализировал письма по содержанию, стилю, тематике и характерным признакам спама.

Итог: все предложенные ему письма совпали с классификацией из датасета. Grok замечает, что разница между spam и ham очень четкая. Для ham писем отмечает, что контекст писем – деловая переписка сотрудников. Письма, помеченные как spam, это «типичный спам того времени»: реклама, пиратство и т. п. В spam имеются искаженные слова, агрессивный маркетинг, подозрительные ссылки и отсутствие контекста, который имеется в ham письмах.

3. Claude (Версия: Sonnet 4.6):

Находил spam по следующим признакам: намеренные опечатки слов, случайные слова в конце письма, сомнительные предложения, тема не соответствует содержанию.

Итог: классификация полностью совпала. ИИ говорит, что набор достаточно прост для классификации, так как видна четкая граница между spam и ham.

4. ChatGPT (Версия: бесплатный план):

Итог: полное совпадение с классификацией в датасете. Указывает на все те же признаки. Для spam: реклама, искажение слов и бессмысленный текст. Для ham: рабочие переписки, нормальная структура

Все системы показали полное соответствие с классификацией из набора данных. ИИ подмечает, что различия между spam и ham видны четко, исходя из нескольких признаков. Одна из систем сказала, что все spam письма того

соответствуют деловым письмам, которые могли отправлять работники компании.

Выводы по четвертому разделу

Набор данных «**Enron Spam Dataset**» - датасет с большим количеством настоящих классифицированных по спаму писем. В нем имеются пропущенные данные, но их очень мало. Набор содержит сбалансированное количество писем, которые помечены как спам и не спам. В датасете только письма на английском языке, что может затруднить обучение модели для классификации писем на русском. Рекомендуется дополнить датасет современными письмами и письмами на других языках.

ЗАКЛЮЧЕНИЕ

В рамках курсового проекта выполнен поиск и первичный анализ наборов данных разных типов по различным областям применения. В ходе выполнения работы были получены следующие основные результаты:

1) подготовлено для каждого типа данных (табличные данные, временные ряды, изображения, тексты) краткое описание выбранной задачи, решение которой связано с применением технологий искусственного интеллекта;

2) подобран и обоснован выбор для каждого типа данных набор данных из авторитетных открытых источников, необходимый для обучения ИИ-модели, решающей соответствующую выбранную задачу;

3) реализован комплекс программ на языке Python, каждая из которых для заданного типа данных выполняет основные функции первичного анализа;

4) сформулированы выводы по каждому этапу анализа, а также итоговое заключение о качестве данных и их пригодности для решения поставленной задачи;

5) размещен исходный код в репозитории системы контроля версий Git:
[ССЫЛКА НА РЕПОЗИТОРИЙ](#).

ЛИТЕРАТУРА

1. Набор данных Fraud_detection_dataset. URL: <https://github.com/rskworld/fraud-detection> (Дата обращения: 01.04.2026).
2. Набор данных Ball Bearing Vibration, and Temperature Run-to-Failure Dataset. URL: <https://data.mendeley.com/datasets/5hcdd3tdvb/6> (Дата обращения: 10.04.2026).
3. Jung, Wonho; Yun, SungHyun; Kim, Junho; Park, Yong-Hwa. Vibration, and temperature run-to-failure dataset of ball bearing for prognostics // Mendeley Data. 2024. V6, DOI: 10.17632/5hcdd3tdvb.6. URL: <https://www.sciencedirect.com/science/article/pii/S235234092400372X>. (Дата обращения: 10.04.2026).
4. Набор данных STORM graffiti/tagging detection dataset. URL: <https://zenodo.org/records/3238357> (Дата обращения: 20.04.2026).
5. Heritage Research Hub: страница проекта STORM (Safeguarding Cultural Heritage through Technical and Organisational Resources Management). URL: <https://www.heritageresearch-hub.eu/project/storm>. (Дата обращения: 20.04.2026).
6. Patrikakis Charalampos, Kasnesis Panagiotis, Toumanidis Lazaros and Tzitamidis Alexandros, "STORM graffiti/tagging detection dataset". Zenodo, Jun. 04, 2019. doi: 10.5281/zenodo.3238357 (Дата обращения: 30.04.2026).
7. Набор данных The Enron-Spam dataset preprocessed in a single, clean csv file. URL: https://github.com/MWiechmann/enron_spam_data?tab=readme-ov-file (Дата обращения: 30.04.2026).
8. Apache SpamAssassin: сайт, предоставляющий фильтр для классификации электронных писем и блокировки спама. URL: <https://spamassassin.apache.org/index.html> (Дата обращения: 30.04.2026).

9. A. Kosmopoulos, G. Paliouras and I. Androutsopoulos, "Adaptive Spam Filtering Using Only Naive Bayes Text Classifiers". Spam Filtering Challenge Competition, *5th Conference on Email and Anti-Spam (CEAS 2008)*, Mountain View, CA, USA, 2008. URL: https://pages.aueb.gr/users/ion/docs/ceas2008_paper.pdf (Дата обращения: 30.04.2026).
10. Майорова Алла Романовна, Карамышева Надежда Сергеевна, Зинкин Сергей Александрович АНАЛИЗ ВЛИЯНИЯ КАЧЕСТВА ДАННЫХ НА ПРОИЗВОДИТЕЛЬНОСТЬ АЛГОРИТМОВ МАШИННОГО ОБУЧЕНИЯ // Вестник ПензГУ. 2024. №4 (48). URL: <https://cyberleninka.ru/article/n/analiz-vliyaniya-kachestva-dannyh-na-proizvoditelnost-algoritmov-mashinnogo-obucheniya> (Дата обращения: 13.04.2026).
11. ChatGPT: [сайт] / OpenAI. — 2024. — URL: <https://chatgpt.com> (дата обращения: 02.05.2026). — Текст: электронный.
12. Gemini: [сайт] / Google. — 2024. — URL: google.com (дата обращения: 30.03.2026). — Текст: электронный.
13. Claude: [сайт] / Anthropic. — 2024. — URL: <https://claude.ai> (дата обращения: 02.05.2026). — Текст: электронный.
14. Grok: [сайт] / xAI. — 2024. — URL: <https://x.ai> (дата обращения: 02.05.2026). — Текст: электронный.