

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Южно-Уральский государственный университет (национальный исследовательский университет)»
Институт естественных и точных наук
Центр «ВиртУм»

Поиск и первичный анализ наборов данных по различным областям применения

09.03.04 «Программная инженерия»

Научный руководитель:
профессор центра ОП топ-уровня в
сфере ИИ «ВиртУм»,
доктор физ.-мат. наук
М.Л. Цымблер

Авторы:
студент группы ЕТ-142
А.В. Галкин

Челябинск, 2026 г.

Актуальность: необходимость первичного анализа

Первичный анализ наборов данных необходим для задач, решаемых с помощью ИИ. Ему необходимы чистые и структурированные данные, которые можно легко проанализировать. Также, исходные данные должны быть достоверными и качественными, чтобы обучить модель. Использование дубликатов, наборов с пропущенными значениями, некорректных форматов и типов данных или сильно выделяющихся данных – аномалий – может привести к тому, что искусственный интеллект не сможет выполнять поставленные задачи. Аномалии могут сформировать ложные закономерности, пропущенные данные поспособствуют образованию ложных обобщений.

Наборы данных могут хранить в себе различную информацию. Существуют датасеты изображений, аудио, табличных данных, текста, временных рядов. Владение навыками первичного анализа данных разных типов является необходимым для специалиста в области искусственного интеллекта, чтобы обучать качественные ML-модели для успешного выполнения ими поставленных задач.

Табличные данные: задача и описание данных

- **Задача:** Классификация финансовых транзакций: мошеннические или обычные
- **Набор данных:**
 - **Название, источник:** Fraud_detection_dataset, GitHub
 - **URL:** <https://github.com/rskworld/fraud-detection>
 - **Описание:** синтетический набор данных, содержащий информацию о 10000 различных транзакциях
 - **Размерность:** 10000 записей, 37 признаков



Табличные данные: основные атрибуты

№	Название	Семантика	Тип	Допустимые значения
1	transaction_id	Идентификатор транзакции	Строка	transaction_id ∈ {"TXN_xxxxxx", ...} x ∈ N
2	user_id	Идентификатор пользователя	Строка	user_id ∈ {"USER_xxxx", ...} x ∈ N
3	amount	Сумма транзакции	Числовой	amount ∈ ℝ
4	merchant_category	Категория операции	Строка	Merchant_category ∈ {'Retail', 'Grocery', 'Restaurant', 'Gas', 'Online', 'Pharmacy', 'Travel', 'Entertainment', 'Utilities', 'Other'}
5	location	Страна	Строка	Location ∈ {"US", "UK", "CA", "AU", "FR", "DE", "IT", "ES", "NL", "BE"}
6	timestamp	Время проведения транзакции	Дата и время	Формат: ГГГГ-ММ-ДД ЧЧ:ММ:СС.МС
7	device_type	Устройство, используемое для транзакции	Строка	Device_type ∈ {"ATM", "Desktop", "Tablet", "POS", "Mobile"}

Табличные данные: основные атрибуты

№	Название	Семантика	Тип	Допустимые значения
8	User_age	Возраст пользователя	Числовой	$18 \leq \text{user_age} \leq 79$ $\text{user_age} \in \mathbb{N}$
9	Account_age_days	Возраст аккаунта в днях	Числовой	$1 \leq \text{account_age_days} \leq 3649$ $\text{account_age_days} \in \mathbb{N}$
10	Transaction_count_24h	Кол-во транзакций за последние 24 часа	Числовой	$1 \leq \text{transaction_count_24h} \leq 2$ $\text{transaction_count_24h} \in \mathbb{N}$
11	Avg_transaction_amount	Средняя сумма транзакции	Числовой	$0.83 \leq \text{avg_transaction_amount} \leq 1566.55$ $\text{avg_transaction_amount} \in \mathbb{R}$
12	is_foreign_transaction	Транзакция из-за рубежа	Бинарный	$\text{is_foreign_transaction} \in \{0, 1\}$
13	Day_of_week	День недели	Числовой	$\text{Day_of_week} \in [0, 6]$ 0 – понедельник
14	Is_fraud (целевая переменная)	Является ли транзакция мошеннической	Бинарный	$\text{Is_fraud} \in \{0, 1\}$

Табличные данные: пример

Transaction_id	user_id	amount	merchant_category	location	timestamp	device_type	user_age	...	Is_fraud
TXN_008015	USER_3121	57.96	Utilities	BE	2025-12-27 14:28:56.834179	Desktop	29	...	0
TXN_006868	USER_2338	8.72	Online	UK	2025-06-08 01:28:56.734369	ATM	55	...	0
TXN_000011	USER_0864	6.03	Gas	FR	2025-10-13 10:45:56.084563	Tablet	46	...	0

Анализ табличных данных

	 Шаг 1. Распределение признаков	 Шаг 2. Качество данных	 Шаг 3. Проверка на диапазоны значений
Результаты	- is_fraud: дисбаланс классов - user_age: равномерное распределение - hour_of_day: равномерное распределение	- Отсутствие пропусков - Выбросы в суммах транзакций: Обычные - 847 (8.9% из 9500) Мошеннические – 53 (10.6% из 500)	Значительное различие в масштабах признаков: $18 \leq \text{user_age} \leq 79$, $1 \leq \text{account_age_days} \leq 3649$, $0.83 \leq \text{avg_transaction_amount} \leq 1566.55$, $0.33 \leq \text{amount} \leq 6015.96$
Действия	is_fraud: учет дисбаланса признака. Добавление мошеннических транзакций	Сохранение выбросов как реальные случаи транзакций	- Категоризация user_age и дальнейшая кодировка (Target Encoding) - Стандартизация признаков: avg_transcation_amount и amount (RobustScaler), account_age_days (StandardScaler)

Анализ табличных данных


	 Шаг 4. Корреляционный анализ	 Шаг 5. Кодирование категор. атрибутов
Результаты	Присутствует корреляция с целевым признаком <code>is_fraud</code> и основными признаками: <code>amount</code> (0.24), <code>account_age_days</code> (-0.33), <code>avg_transaction_amount</code> (0.13), <code>is_foreign_transaction</code> (0.19), <code>hour_of_day</code> (-0.13)	Кол-во категорий: <code>merchant_category</code>: 10 <code>location</code>: 10 <code>device_type</code>: 5
Действия	Использование признаков для построения ИИ модели	Target encoding: <code>merchant_category</code>, <code>location</code>, <code>device_type</code>

Временные ряды: задача и описание данных

- **Задача:** Прогнозирование скорой поломки подшипника, исходя из его температуры и вибрации


- **Набор данных:**

- **Название, источник:** Ball Bearing Vibration, and Temperature Run-to-Failure Dataset, Jung, Wonho; Yun, SungHyun; Kim, Junho; Park, Yong-Hwa. Vibration, and temperature run-to-failure dataset of ball bearing for prognostics // Mendeley Data. 2024. V6
- **URL:** <https://doi.org/10.17632/5hcdd3tdvb.6>
- **Описание:** был создан испытательный стенд для шарикоподшипников, предназначенный для ускоренного испытания на долговечность. Он вращался с постоянной скоростью до тех пор, пока не вышел из строя. Данные о вибрации измерялись с помощью двух акселерометров (печатная плата 352C34), установленных на корпусе подшипника. На поверхности подшипника была установлена термопара (K-типа)



Временные ряды: визуализация

4 измерения



258000000 значений (129 часов: 72 сек каждый час)

- Резкое увеличение вибрации по оси X и Y после 120 часов работы
- Постепенное повышение температуры подшипника

Итог: остановка замеров после 129 часов работы в связи с поломкой подшипника

Характеристики подшипника:

- Модель: NSK 6205
- Вес: 0.13 кг
- Внутренний диаметр: 25 мм
- Наружный диаметр: 52 мм
- Максимальная частота вращения об/мин (скорость во время исследования: 1770 – 1780 об/мин)
- Номинальные статическая и динамическая нагрузки: 7.8 кН и 14.8 кН (осевая и вертикальная нагрузка во время исследования: 2.94 кН, 5.88 кН)



Анализ временных рядов

	 Шаг 1. Качество данных	 Шаг 2. Корреляционный анализ
Результаты	• Присутствие небольшого количества пропусков во всех измерениях: Vibration_X (0.002-0.004%), Vibration_Y (0.002-0.004%), Temp_Bearing (0.002-0.0041%), Temp_Atmosphere (0.002-0.0041%) • Самая длинная цепь пропусков из 41 строки • Присутствуют выбросы в измерениях Vibration_X и Vibration_Y (0.009% и 0.014%).	• Линейные взаимосвязи между измерениями: $r(\text{Vibration_X}, \text{Vibration_Y}) = 0.2$; $r(\text{Temp_Bearing}, \text{Temp_Atmosphere}) = 0.6$
Действия	• Избавление от пропусков: линейная интерполяция (.interpolate) или удаление записей ввиду малой доли потерь • Сохранение выбросов и добавление нового измерения для подсчета кол-ва выбросов за определенный промежуток времени	• Использование всех измерений для прогнозирования поломки • Добавить новое измерение Temp_Diff = Temp_Bearing – Temp_Atmosphere, чтобы ИИ не принимал повышение температуры атмосферы за поломку подшипника

Анализ временных рядов



Шаг 3. Проверка на диапазоны значений

Результаты

Виден сильный разброс по значениям:

- $\text{Vibration_X} \in [-51.02; 39.695]$
- $\text{Vibration_Y} \in [-44.484; 10.688]$
- $\text{Temp_Bearing} \in [30.095; 108.84]$
- $\text{Temp_Atmosphere} \in [24.407; 26.77]$

Действия

- Стандартизация признаков с помощью RobustScaler из scikit-learn, из-за разных величин признаков

Анализ временных рядов

Шаг 5.



Разложение на компоненты (декомпозиция температуры и вибрации)

Результаты

- Получены тренды и сезонности для файлов, где подшипник исправен и неисправен, из-за большого объема данных

Температура:

- При исправном подшипнике сезонность имеет маленькую амплитуду и плавно повышающийся тренд и низкая амплитуда шумов
- При неисправном подшипнике тренд и шум имеет форму волны. У сезонности, тренда и шума увеличился диапазон

Вибрация:

- Увеличение диапазона при неисправном подшипнике у графиков тренда, сезонности и шума примерно в 4 раза. Причины: вал перестал вращаться ровно (увеличилась амплитуда тренда), оборот вала сопровождается ударом (сезонность увеличилась), шумов при неисправном подшипнике намного больше (увеличение разброса шума)

Анализ временных рядов



Шаг 6. Поиск и анализ шумов

Результаты	Показатель SNR в диапазоне 5–20 дБ, Среднеквадратичное значение RMS от 0.3-0.5 до 1.4-1.6: $SNR_{Temp_Bearing} = 19.79$ – подшипник исправен; $SNR_{Temp_Bearing} = 5.06$ – подшипник неисправен; $RMS_{Vibration_X} = 0.3621$ – подшипник исправен; $RMS_{Vibration_X} = 1.4518$ – подшипник неисправен; $RMS_{Vibration_Y} = 0.5714$ – подшипник исправен; $RMS_{Vibration_Y} = 1.5896$ – подшипник неисправен
Действия	- Умеренный уровень шума: шум не будет замечен, когда подшипник исправен. При поломке подшипника появляется больше шумов, что понижает SNR – это и есть показатель неисправности - RMS показывает энергию вибрации, которая повысилась в 3-4 раза - Данные пригодны для анализа

Изображения: задача и описание данных

- **Задача:** детекция граффити на фото



- **Набор данных:**

- **Название, источник:** STORM graffiti/tagging detection dataset, Patrikakis Charalampos, Kasnesis Panagiotis, Toumanidis Lazaros and Tzitamidis Alexandros, “STORM graffiti/tagging detection dataset”. Zenodo, Jun. 04, 2019. doi: 10.5281/zenodo.3238357
- **URL:** <https://doi.org/10.5281/zenodo.3238356>
- **Описание:** набор данных Университета Западной Аттики (Греция) собран из фото, которые сделаны в муниципалитете Афин и его пригороде, где были обнаружены граффити на различных поверхностях. Датасет состоит из 1022 изображений и их разметки в файлах формата CSV

Изображения: основные атрибуты

№	Название	Семантика	Тип	Допустимые значения
1	filename	Имя файла с форматом	Строка	filename $\in$ {"IMG_1262.jpg" , ...}
2	width	Ширина картинки	Числовой	width = 720
3	height	Высота картинки	Числовой	height = 960
4	class	Класс объекта на изображении	Строка	class $\in$ {"Graffiti"}
5	xmin, ymin	Левая верхняя точка квадрата	Числовой	0 <= xmin <= 705 0 <= ymin <= 934
6	xmax, ymax	Правая нижняя точка квадрата	Числовой	11 <= xmax <= 720 16 <= ymax <= 960

Изображения: структура разметки граффити

- Формат схож со стандартом разметки Pascal VOC
- Сравнение Pascal VOC и собственной разметки набора данных


	Датасет	Pascal VOC
Формат файлов	CSV	XML
Координаты боксов	filename, width, height, class, xmin, ymin, xmax, ymax	<filename>, <width>, <height>, <name>, <xmin>, <ymin>, <xmax>, <ymax>

Анализ изображений



Шаг 1. Качество данных

- Пропущенных данных нет:
filename - 0%, width - 0%, height - 0%, xmin - 0%,
ymin - 0%, xmax - 0%, ymax - 0%



Шаг 2. Анализ распределения классов

- Class: каждый файл имеет класс Graffiti, что означает наличие граффити в каждом изображении. Это подтверждает, что набор данных относится к задаче детекции

Результаты

Анализ изображений

	Шаг 3. Σ Количество граффити на фото	Шаг 4. S Площадь, занимаемая граффити
Результат	- В большинстве случаев на фотографиях встречаются от 1 до 5 граффити - Максимальное количество граффити на фото 25	- В большинстве случаев граффити занимают до 40% - Процент площади фотографии, который занимают граффити: 9.4% - Максимально занятый процент площади: 62.78% - Присутствует наложение боксов. Максимальное наложение: 57.97%
Действия	Так как есть фото, где большой процент наложения объектов, требуется настроить порог NMS (алгоритм, который убирает лишние дублирующие рамки) выше 0.57. Без этого модель может удалить один из боксов, подсчитав, что это разметка одного объекта	

Текст: задача и описание данных

- **Задача:** классификация электронных писем:
не спам / спам




- **Набор данных:**
 - **Название, источник:** Enron Spam Dataset, V. Metsis, I. Androutsopoulos, G. Paliouras, GitHub, Aueb.gr
 - **URL:** https://github.com/MWiechmann/enron_spam_data?tab=readme-ov-file, <https://pages.aueb.gr/users/ion/data/enron-spam/index.html>
 - **Описание:** файл формата .csv с информацией о письмах и сами сообщения. Всего в датасете 33716 писем на английском языке. Он был составлен на основе статьи «Spam Filtering with Naive Bayes - Which Naive Bayes?». Авторы статьи использовали корпус сообщений «SpamAssassin», в котором хранятся настоящие классифицированные электронные письма.

Текст: атрибуты

№	Название	Семантика	Тип	Допустимые значения
1	Message ID	Порядковый номер сообщения в датасете	Числовой	Message ID $\in$ [0; 33715]
2	Subject	Тема письма	Строка	$\forall$
3	Message	Текст письма	Строка	$\forall$ (включая чувствительные данные)
4	Spam/Ham (целевая переменная)	Классификация письма	Строка	Spam/Ham $\in$ {spam, ham}
5	Date	Дата отправки письма	Дата	Дата в формате ГГГГ-ММ-ДД

Анализ текста

	Шаг 1. Качество данных	Шаг 2. Баланс классов
Результаты	Пропуски: Message ID: 0 (0%), Subject: 289 (0.86%), Message: 371 (1.11%), Spam/Ham: 0 (0%), Date: 0 (0%)	Spam/Ham: spam: 17171 (50.93%), ham: 16545 (49.07%)
Действия	Наличие пропусков в Subject и Message можно объяснить следующим: отсутствие темы или текста в письме	Равномерное распределение и большое количество spam и ham сообщений

Анализ текста

	Шаг 3. Анализ количества слов и длин в письмах у тем и сообщений	Шаг 4. Сравнение классов писем в определенном диапазоне слов
Результаты	- Спам письма отличаются меньшим количеством слов в сообщениях и большим числом слов в темах - Среднее количество символов в письмах: ~1500	- Было вычислено количество слов в письме, при котором доля у spam писем больше, чем у ham: до 160 слов - Вероятность встретить спам в письмах до 160 слов: 0.549 - Вероятность встретить спам в письмах, где более 160 слов: 0.446
Действия	- Письма с длинными темами с коротким содержимым: стратегия, по которой работает spam в датасете. Так выше вероятность, что человек попадет на уловку письма. Необходимо создать новые признаки: длина темы и длина сообщения. Это потребует нормализацию методом TF-IDF (вычисление веса слова в письме $\times$ во всем наборе данных) - Из-за большого количества вариаций длин писем, написания слов и т.п., требуется нормализация текста (библиотека nltk для обработки естественного языка): приведение к единому регистру и начальной форме, удаление предлогов, союзов и пунктуации	

Анализ текста

Шаг 5.

Генерация облаков тегов и анализ содержимого писем

Результаты

Были сделаны два облака: облака ham и spam писем:

- Слова из облака spam писем: click, link, free, email, site, money
- Слова из облака ham писем: deal, time, million, billion, Dynegy, project

Главная проблемы датасета: множество чувствительных данных (Dynegy – название компании, имена сотрудников, номера телефонов, электронные почты) и URL-ссылки

Действия

- Требуется анонимизировать чувствительные данные, скрыть различные ссылки (например, замена на токены URL)
- Настройка частоты слов и стоп-слов: игнорировать слова, которые часто встречаются и почти не встречаются во всех письмах. Игнорировать определенные слова, которые занесены в список. (Например, союзы и предлоги)

Анализ текста

Шаг 6.

Исследование с использованием GPT-систем

Результаты	• Нескольким системам были даны конкретные одинаковые письма, которые они классифицировали сами. У всех систем ИИ классификация совпала с классификацией из набора данных • Все GPT-системы опирались на: стиль написания (например, попытка обхода фильтров), характерные признаки для спама (срочность, обещания заработка, странные ссылки, нетипичные заголовки)
Действия	• В отличие от классических моделей (Байесовский классификатор, случайный лес, SVM) для классификации писем, GPT может анализировать семантику письма. Большие языковые модели можно использовать для анализа сложных случаев, но для обработки большого количества писем в реальном времени лучше всего использовать классические варианты

Основные результаты


1. подготовлено краткое описание выбранной задачи ИИ для каждого типа данных (таблицы, временные ряды, изображения, тексты);
2. подобраны и обоснован выбор наборов данных из открытых источников;
3. реализован комплекс программ на языке Python для первичного анализа;
4. сформулированы рекомендации по предобработке данных;
5. размещен исходный код в Git-репозитории: **ССЫЛКА НА РЕПОЗИТОРИЙ**.

Анализ табличных данных: пропуски и выбросы

- Пропуски отсутствуют

Признак	Количество пропусков	Доля пропусков, %
Transaction_id	0	0
User_id	0	0
Amount	0	0
Merchant_category	0	0
Location	0	0
timestamp	0	0
Device_type	0	0
User_age	0	0
Account_age_days	0	0
Avg_transaction_amount	0	0
Is_foreign_transaction	0	0
Day_of_week	0	0
Is_fraud	0	0


- Присутствуют выбросы в **amount** как у обычных транзакций, так и у мошеннических




Обычные транзакции	Мошеннические транзакции
847 (8.9% из 9500)	53 (10.6% из 500)

Анализ табличных данных: тепловые карты

- Числовые признаки слабо коррелируют с is_fraud
- Мультиколлинеарность присутствует





- Мошеннические транзакции происходят в нерабочие часы




Анализ табличных данных: распределения числовых атрибутов

Возможна категоризация




Анализ табличных данных: распределения категориальных атрибутов

Дисбаланс: 9500 и 500



Равномерное распределение



Анализ табличных данных: кодирование

Категориальный признак:

- $\text{location} \in \{'BE', 'UK', 'FR', \dots\}$
- $\text{Device_type} \in \{\text{Desktop}, \text{ATM}, \dots\}$
- $\text{Merchant_category} \in \{'Utilities', 'Online', \dots\}$

Target Encoding



- $\text{Location} \in \{0.048228, 0.054598, 0.054082, \dots\}$
- $\text{Device_type} \in \{0.047925, 0.049189, \dots\}$
- $\text{Merchant_category} \in \{0.050505, 0.049116\}$

	is_fraud	merchant_category	device_type	location
0	0	Utilities	Desktop	BE
1	0	Online	ATM	UK
2	0	Gas	Tablet	FR
3	0	Travel	POS	BE
4	0	Other	POS	AU
	is_fraud	merchant_category	device_type	location
0	0	0.050505	0.047925	0.048228
1	0	0.049116	0.049189	0.054598
2	0	0.038424	0.050952	0.054082
3	0	0.051844	0.052037	0.048228
4	0	0.044821	0.052037	0.048632
PS C:\Users\Aleks>				

Анализ временных рядов: статистика

	Vibration_X	Vibration_Y	Temp_Bearing	Temp_Atmosphere
Count	2.579937e+08	2.579937e+08	2.579896e+08	2.579896e+08
Mean	0.006587737	0.01444664	42.54523	25.49339
Std	0.4234042	0.6534180	11.43994	0.5129180
Min	-51.02237	-44.48412	30.09578	24.40789
Q1	-0.1459880	-0.2555203	36.50803	25.12951
Q2	0.04579356	0.04950974	39.69116	25.57302
Q3	1.036248	1.134837	44.87347	25.78651
Max	39.69520	10.68812	108.8404	26.77077

Анализ временных рядов: пропуски и выбросы


- Пропуски в данных присутствуют
- Выбросы присутствуют в Vibration X и Vibration Y

	Пропуски (%)	Выбросы (аномалии)
Vibration_X	0.002-0.004	2352734
Vibration_Y	0.002-0.004	3698449
Temp_Bearing	0.002-0.0041	-
Temp_Atmosphere	0.002-0.0041	-




Анализ табличных данных: корреляция, диапазоны значений

- Слабая линейная зависимость между Vibration_X и Vibration_Y, сильная линейная зависимость между Temp_Bearing и TempAtmosphere




- Масштабы измерений многомерного ряда **значительно различаются**




Анализ временных рядов: декомпозиция

Ряд Temp_Bearing (Исправный. Сезонность: 1 час)



SNR исправного подшипника: 19.79 дБ


Ряд Temp_Bearing (Поврежденный. Сезонность: 1 час)




SNR неисправного подшипника: 5.06 дБ

Анализ временных рядов: декомпозиция

Ряд Vibration_X (Исправный)




Ряд Vibration_X (Поврежденный)




Анализ временных рядов: декомпозиция

Ряд Vibration_Y (Исправный)



Ряд Vibration_Y (Поврежденный)



Анализ изображений: пропуски и примеры

- Пропуски **отсутствуют**


Filename	0
width	0
height	0
Class	0
Xmin	0
Ymin	0
Xmax	0
ymax	0

- Примеры изображений




Анализ изображений: количество граффити на фото

- На большинстве изображений **от 1 до 5** граффити



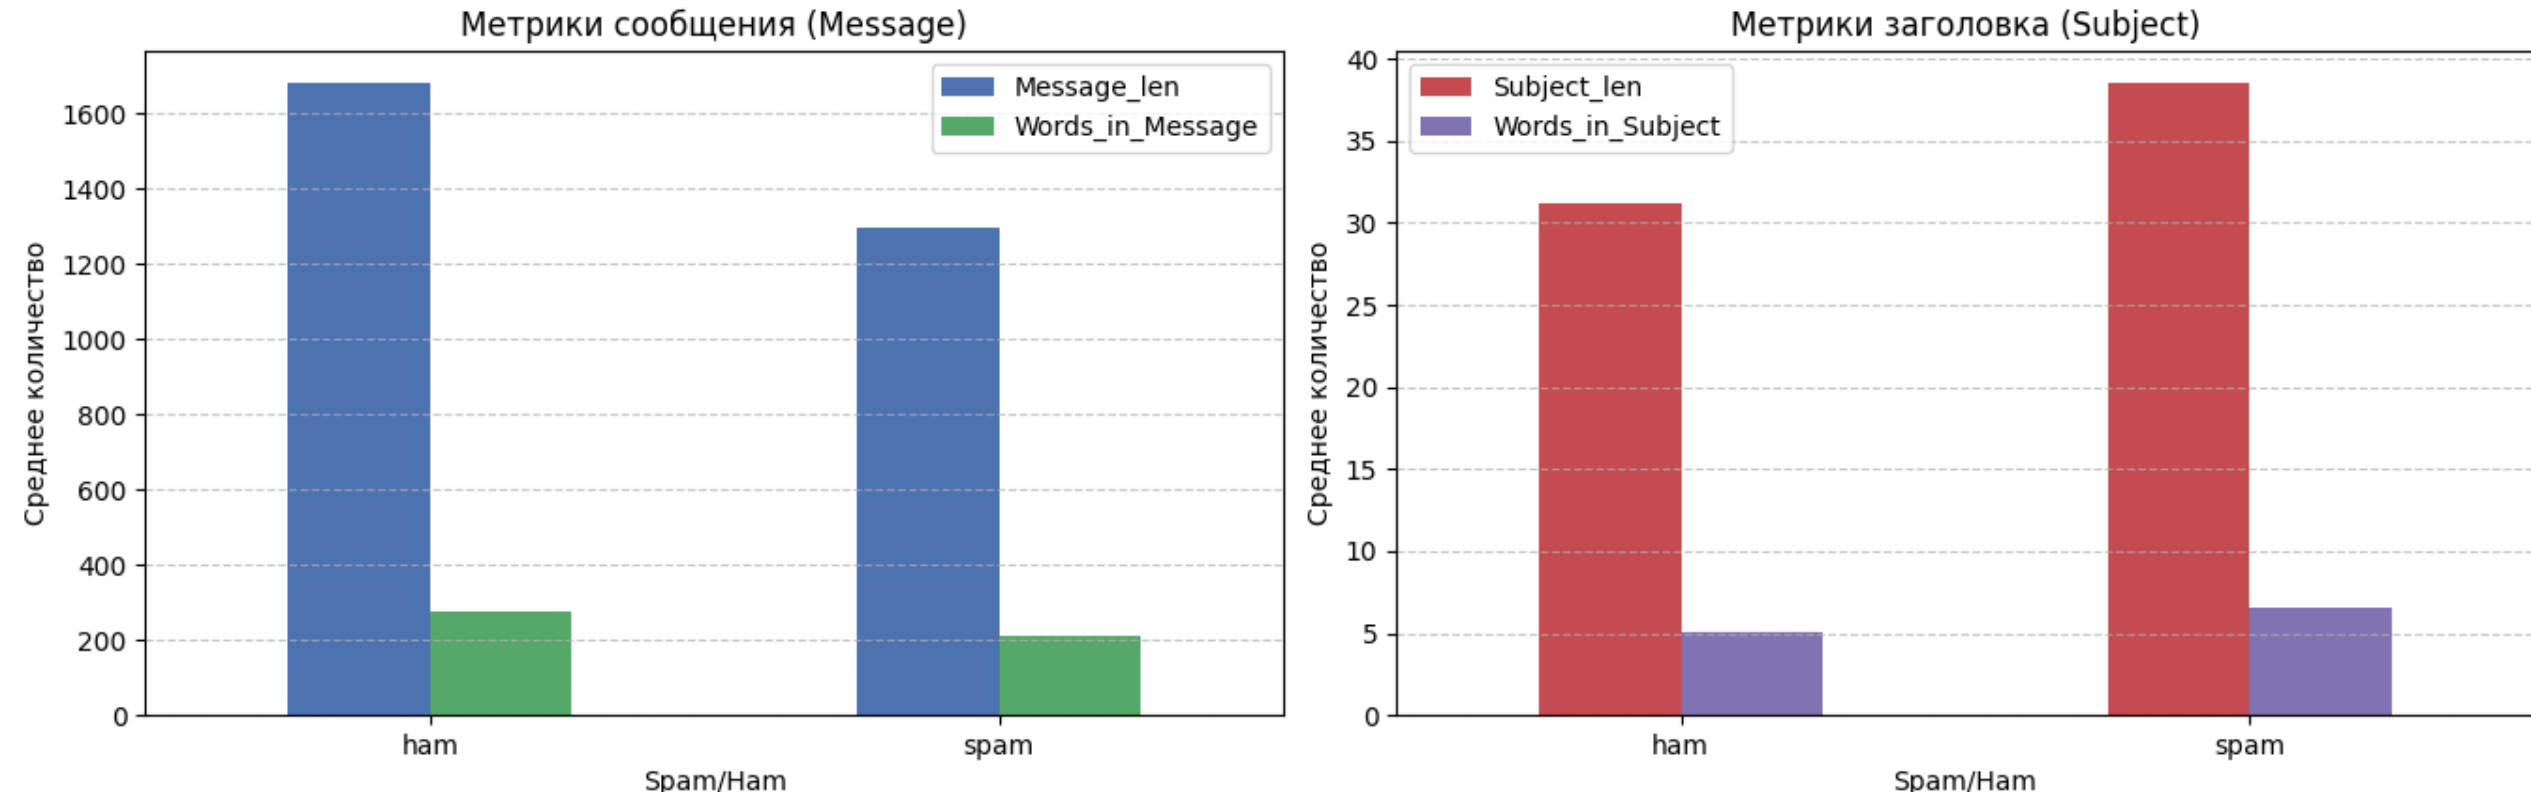
Анализ изображений: доля площади фото, занимаемая граффити

Распределение реальной площади граффити на фотографиях (с учетом наложений)




- При расчете занимаемой площади учитывалось наложение боксов друг на друга
- В среднем граффити занимают 9.40% от площади фото
- В большинстве случаев доля составляет до ~25%
- Есть редкие случаи, где процент превышает 40%

Анализ текста: длина сообщений и тем в письмах



Анализ текста: сравнение классов писем по порогу слов



Анализ текста: использование GPT-систем для классификации писем

Модель	Версия	Критерии анализа	Итог	Особенности ham	Особенности spam
Gemini	3.1 flash-lite	Содержание, стиль, спам-признаки (срочность, обещания заработка, странные ссылки, нетипичные заголовки), контекст корпоративной переписки	Полное совпадение с классификацией	Имена сотрудников, рабочие процессы, диалог, слэнг	Методы обхода фильтров: разбивка слов, неуместные символы; письмо 18139 — много случайных слов
Grok	Fast	Содержание, стиль, тематика, спам-признаки		Деловая переписка сотрудников	Типичный спам того времени: реклама, пиратство; искаженные слова, агрессивный маркетинг, подозрительные ссылки, отсутствие контекста
Claude	Sonnet 4.6	Намеренные опечатки, случайные слова в конце, сомнительные предложения, несоответствие темы содержанию		Конкретные имена и адреса, цепочки пересылок, бизнес-контент	Намеренные опечатки, случайные слова в конце, сомнительные предложения, тема не соответствует содержанию
ChatGPT	Бесплатный план	Те же критерии		Рабочие переписки, нормальная структура	Реклама, искажение слов, бессмысленный текст